

Predição de surtos de dengue no Brasil: uma abordagem baseada em dados epidemiológicos e fatores associados

Davi Albini^{1*}; Lilian da Silveira²

¹ Bacharel em Engenharia de Bioprocessos e Biotecnologia. Rua Francisco Juglair, 410 – Mossunguê; 81200-230 Curitiba, Paraná, Brasil

² Mestre e Doutora em Ciências, Cientista de Dados Sênior. Rua João Pio Duarte Silva, 524 – Córrego Grande; 88037-000 Florianópolis, Santa Catarina, Brasil

*autor correspondente: davialb23@gmail.com

Predição de surtos de dengue no Brasil: uma abordagem baseada em dados epidemiológicos e fatores associados

Resumo

Este trabalho abordou a predição de casos de dengue no Sudeste do Brasil a partir de dados públicos e justificou-se pela necessidade de transformar a vigilância reativa em gestão proativa de risco. Teve como objetivo construir e avaliar uma modelagem reprodutível que antecipou, em escala municipal e frequência semanal, a dinâmica epidêmica da dengue. O estudo coletou, limpou, integrou e agregou notificações [SINAN] e variáveis climáticas [INMET], estratificou municípios de interesse e definiu 2023 como janela de teste. Avaliaram-se diferentes modelos univariados (“Naive”, “Mean”, “Drift”, SES, Holt, Holt-Winters, ARIMA, SARIMA) e multivariados com variáveis climáticas defasadas (GLM de contagem, árvores/ensembles e LSTM). A comparação de resultados entre modelos foi realizada por RMSE (principal), MAE e MAPE, e o melhor modelo foi escolhido por município. As séries e previsões foram sintetizadas em gráficos semanais. Evidenciou-se que, em cenários menos sensíveis ao clima, modelos univariados, especialmente SARIMA, apresentaram desempenho superior, ao passo que, nos municípios onde o clima apresentou maior correlação com notificações, LSTM e GLMs de contagem apresentaram a melhor aderência. O modelo de melhor desempenho variou entre localidades, refletindo a influência do regime epidêmico. Concluiu-se que a estratégia de modelagem em duas frentes permitiu adaptar as previsões ao perfil de cada município e viabilizou cenários de antecipação úteis ao planejamento de ações no contexto da saúde pública.

Palavras-chave: séries temporais; epidemiologia; modelagem preditiva; dados públicos; saúde urbana.

Introdução

A dengue é uma das doenças virais mais preocupantes no mundo e representa um grave problema de saúde pública, especialmente em países tropicais como o Brasil. Causada pelo vírus da dengue [DENV], um arbovírus da família *Flaviviridae*, a doença é transmitida principalmente pelo *Aedes aegypti* e, em menor escala, pelo *Aedes albopictus* (Torres-Flores et al., 2022).

Atualmente, aproximadamente metade da população mundial vive em áreas de risco para dengue. A Organização Mundial da Saúde [OMS] estima que 100 a 400 milhões de pessoas sejam infectadas anualmente, resultando em cerca de 40.000 mortes (Messina et al., 2014; Zeng et al., 2021). A América Latina, em particular, tem sido um dos epicentros da doença, devido às condições climáticas favoráveis para a proliferação do mosquito vetor e à urbanização desordenada (Lopez-Gatell et al., 2015; Gutiérrez-Bugallo et al., 2020).

Entre os países da região, o Brasil se destaca como um dos mais afetados, concentrando uma parcela significativa dos casos de dengue. Nos últimos anos, o país tem enfrentado um aumento alarmante na incidência da doença, com um crescimento de 442% entre 2000 e 2024, passando de 2,07 milhões de casos prováveis (2000-2004) para 11,23 milhões (2020-2024). Em 2024, a incidência da dengue foi cinco vezes maior do que no

mesmo período de 2023, consolidando o maior surto já registrado no país. (Gurgel-Gonçalves et al., 2024).

Diversos fatores têm contribuído para a disseminação crescente da doença, são eles: aumento da temperatura e a intensificação das chuvas, que criam condições ideais para a proliferação do *Aedes aegypti* (Abdullah et al., 2022); expansão de áreas urbanas sem infraestrutura adequada de saneamento, o que favorece criadouros do mosquito (Lessa et al., 2023); baixa eficiência no controle vetorial, apesar dos esforços do Ministério da Saúde, o controle do mosquito ainda enfrenta desafios, como resistência a inseticidas e dificuldades na eliminação de criadouros (Gurgel-Gonçalves et al., 2024); por fim, a elevada circulação de múltiplos sorotipos do vírus da dengue (DENV-1, DENV-2, DENV-3 e DENV-4) no Brasil aumentam a probabilidade de infecções secundárias e casos graves (Teixeira et al., 2013).

Além do custo social e sanitário, a dengue impõe altos custos econômicos ao Brasil. Segundo Martelli et al. (2015), os gastos anuais com a doença ultrapassam US\$ 1 bilhão, incluindo custos diretos com hospitalizações e despesas indiretas associadas à perda de produtividade.

Diante desse cenário, prever surtos de dengue com antecedência é fundamental para mitigar os impactos da doença. Modelos preditivos baseados em Ciência de Dados e “Machine Learning” (Aprendizado de Máquina) podem contribuir para essa lacuna, permitindo a antecipação de picos epidêmicos e a melhor alocação de recursos de saúde pública (Gurgel-Gonçalves et al., 2024).

Embora o Brasil disponha de bases robustas como o DataSUS, o Instituto Nacional de Meteorologia [INMET] e outras fontes institucionais, a utilização dessas informações para previsões epidemiológicas ainda é limitada. Assim, este estudo buscou preencher essa lacuna por meio da construção de um modelo preditivo que não apenas antecipe surtos da doença, mas também identifique variáveis-chave associadas à sua incidência, permitindo uma atuação mais estratégica na mitigação de impactos.

Material e Métodos

Este estudo caracterizou-se como uma pesquisa quantitativa e preditiva, baseada na análise de dados epidêmicos e variáveis ambientais, climáticas e demográficas associadas à dengue no Brasil.

Foram utilizadas bases de dados públicas e oficiais, garantindo transparência e reprodutibilidade. Os dados epidêmicos foram obtidos do DataSUS, os meteorológicos do Instituto Nacional de Meteorologia [INMET] e os demográficos e de infraestrutura urbana do Instituto Brasileiro de Geografia e Estatística [IBGE]. Por se tratar exclusivamente de dados

secundários de domínio público, sem acesso a informações pessoais, este estudo não demandou submissão ao Comitê de Ética em Pesquisa, conforme a Resolução CNS nº 510 de 2016.

A coleta dos dados epidêmicos da dengue foi realizada por meio de conexão direta com o repositório "Base dos Dados", hospedado no Google BigQuery, com atualização semanal das informações. Os dados foram organizados por meio de scripts em SQL e Python, incluindo etapas de extração, limpeza, normalização, enriquecimento e integração entre bases. Foram realizadas análises descritivas temporais e espaciais da dengue entre 2000 e 2025 em escala nacional.

Em seguida, procedeu-se à estratificação dos dados por região geográfica, identificando-se padrões e definindo-se a região Sudeste como foco do estudo devido à expressiva carga epidemiológica.

Para seleção dos municípios prioritários do Sudeste, definiram-se dois critérios principais: (i) população média entre 2013 e 2024 igual ou superior a 500 mil habitantes (segundo dados anuais do IBGE); e (ii) incidência média de dengue superior a 500 casos por 100 mil habitantes no mesmo período. Esses critérios garantiram a inclusão de municípios representativos tanto do ponto de vista demográfico quanto epidêmicos, permitindo evitar ruídos estatísticos e viabilizando a integração de variáveis climáticas.

A obtenção dos dados climáticos foi realizada a partir das estações meteorológicas do INMET. Utilizou-se a biblioteca Python HydroBr para listar todas as estações disponíveis, com suas respectivas latitudes e longitudes. Em seguida, aplicou-se a métrica de Haversine, por meio do algoritmo "Ball Tree", para calcular a menor distância geográfica entre cada município estudado e as estações disponíveis. Com isso, foi possível associar a cada município a estação meteorológica mais próxima.

Os dados climáticos dessas estações foram então obtidos diretamente junto ao INMET, mediante solicitação via sistema de requisição disponibilizado em seu site oficial. As variáveis utilizadas incluíram: Precipitação total (mm), Pressão atmosférica média (hPa), Temperatura média (°C), Temperatura máxima (°C), Temperatura mínima (°C), Umidade relativa média (%), Umidade relativa mínima (%) e Velocidade média das rajadas de vento (m/s).

Para integrar essas variáveis aos modelos preditivos, foi conduzida uma análise de defasagem temporal ("lag"), considerando a hipótese de que os efeitos climáticos sobre a incidência de dengue não ocorrem de forma imediata. A análise de "lag" consistiu em testar diferentes deslocamentos temporais das variáveis climáticas em relação à série de notificações da dengue, visando identificar os períodos de maior correlação, conforme exemplificado por Hyndman e Athanasopoulos (2018). Essa abordagem é coerente com os ciclos biológicos do vetor e da doença, que envolvem incubação, proliferação e transmissão,

exigindo um intervalo de tempo entre a ocorrência de eventos climáticos e o aumento de casos.

Antes da construção dos modelos preditivos, aplicaram-se testes estatísticos para avaliar a estacionariedade das séries temporais, condição essencial para modelos como ARIMA e SARIMA (Hyndman e Athanasopoulos, 2018). Foram utilizados três testes consagrados: o teste de Dickey-Fuller [ADF], que tem como hipótese nula a não estacionariedade; o teste Kwiatkowski-Phillips-Schmidt-Shin [KPSS], cuja hipótese nula é a estacionariedade da série; e o teste Phillips-Perron [PP], também voltado à verificação da presença de raiz unitária (Hyndman e Athanasopoulos, 2018). O uso combinado de ADF e KPSS permitiu uma confirmação cruzada dos resultados, reforçando a robustez da análise. Todos os municípios avaliados apresentaram séries estacionárias, possibilitando o uso dos modelos ARIMA e SARIMA sem necessidade de transformações adicionais.

A etapa de modelagem foi conduzida em duas frentes: modelos preditivos univariados e multivariados. Nos modelos univariados, considerou-se exclusivamente a série histórica de notificações de dengue de cada município, com o objetivo de estabelecer uma linha de base preditiva. O ano de 2023 foi escolhido como janela de teste por apresentar padrão cíclico consistente na maior parte dos municípios, sem os desvios extremos de 2024 (ano marcado por surto excepcional). A exclusão de 2024 e 2025 evitou distorções na validação e assegurou maior estabilidade aos testes.

Os modelos univariados testados foram agrupados em três categorias

1. Modelos Simples: “Naive”, Mean” e “Drift” (Hyndman e Athanasopoulos, 2018);
2. Modelos de Suavização Exponencial: SES, Holt e Holt-Winters Aditivo (Hyndman e Athanasopoulos, 2018);
3. Modelos Clássicos de Séries Temporais (Hyndman e Athanasopoulos, 2018): ARIMA e SARIMA (com sazonalidade anual de 52 semanas).

Na segunda frente de modelagem foram desenvolvidos modelos multivariados incorporando as variáveis climáticas defasadas. Esses modelos foram agrupados em três classes principais:

1. Modelos Lineares Generalizados [GLMs] de Contagem: incluindo regressão Poisson e binomial negativa (Fávero, 2017);
2. Modelos baseados em Árvores de Decisão e Ensembles (VanderPlas, 2023): incluindo Decision Tree Regressor, Random Forest Regressor, Gradient Boosting e XGBoost;
3. Modelos de Redes Neurais (Skansi, 2018): com aplicação de “Long Short-Term Memory” [LSTM].

A avaliação de desempenho foi conduzida com base em três métricas consolidadas na literatura: o Erro Absoluto Médio [MAE], que mensura a média dos erros absolutos entre os

valores previstos e os observados; o Erro Percentual Absoluto Médio [MAPE], que expressa a precisão da previsão em termos relativos; e a Raiz do Erro Quadrático Médio [RMSE], que dá maior peso a erros de maior magnitude, sendo por isso adotada como métrica principal neste estudo.

Todos os modelos foram treinados com dados históricos (anos anteriores a 2023) e testados especificamente sobre as notificações reais do ano de 2023. Nos modelos multivariados, além da série histórica, foram utilizadas variáveis climáticas. Para cada município, o modelo com menor RMSE na janela de teste foi considerado o melhor modelo preditivo.

Essas etapas permitiram estabelecer uma linha de base com os modelos univariados e avançar para abordagens mais robustas com os modelos multivariados, ampliando a capacidade preditiva e permitindo análises mais aprofundadas dos fatores associados aos surtos de dengue.

Resultados e Discussão

Inicialmente, realizou-se uma análise exploratória em escala nacional, com o intuito de compreender os padrões gerais de ocorrência e sazonalidade da dengue no Brasil. Em seguida, a análise foi estratificada por regiões, com destaque para a Região Sudeste, cuja expressividade nos dados motivou sua seleção como foco prioritário do estudo. A partir dessa delimitação, procedeu-se à escolha criteriosa de municípios representativos, considerando aspectos como volume de notificações, regularidade temporal e relevância epidemiológica. Essa hierarquização territorial foi essencial diante das limitações computacionais impostas pela incorporação de variáveis externas, como dados climáticos e demográficos.

Com os municípios selecionados, aplicaram-se modelos univariados de séries temporais, com base exclusivamente no histórico de notificações, visando construir uma linha de base (“baseline”) para avaliação comparativa. Essa etapa permitiu identificar os limites dos modelos clássicos na previsão da série e reforçou a hipótese da influência de fatores exógenos sobre os surtos de dengue, especialmente os de natureza ambiental.

Diante disso, foi conduzida uma nova etapa analítica, com a incorporação de variáveis climáticas obtidas por meio de estações meteorológicas do Instituto Nacional de Meteorologia [INMET], associadas a cada município por proximidade geográfica. As séries dessas variáveis foram enriquecidas por meio de uma análise de defasagem temporal (“lag analysis”), de forma a capturar relações latentes entre alterações no clima e os registros de dengue ao longo do tempo.

A partir dessa base multivariada, foram aplicados três grupos distintos de modelos supervisionados: (i) modelos lineares generalizados [GLM] de contagem, como regressão Poisson e binomial negativa; (ii) modelos baseados em árvores de decisão e ensemble, como Random Forest, Gradient Boosting e XGBoost; e (iii) redes neurais do tipo LSTM. Os resultados desses modelos foram comparados com os univariados em termos de acurácia preditiva e interpretabilidade.

Os achados apresentados a seguir estão organizados conforme essa lógica territorial e analítica.

Análise temporal e espacial da dengue no Brasil e seleção da região de estudo

A análise da série histórica de notificações de dengue no Brasil entre os anos de 2000 e 2024 revela um cenário de intensificação progressiva da doença. Conforme ilustrado na Figura 1, o número de casos anuais evidenciou flutuações recorrentes, com sucessivos picos epidêmicos em intervalos de dois a quatro anos, até culminar em um pico sem precedentes em 2024, com mais de 6,4 milhões de notificações.

Esse marco configura a maior epidemia já registrada no país, representando um aumento de mais de 400% em relação à média da década de 2000, conforme já apontado por Gurgel-Gonçalves et al. (2024).




Figura 1. Total de notificações anuais de dengue no Brasil (2000–2025)

Fonte: Resultados originais da pesquisa

Considerando a distribuição semanal média dos casos por todo o período (Figura 2), observa-se um padrão sazonal bastante característico: o número de notificações começa a subir nas primeiras semanas epidemiológicas do ano, atingindo o ápice entre as semanas 10 e 15, e recuando progressivamente até a semana 30. Esse comportamento reforça a natureza

cíclica e climatologicamente condicionada da doença, com maior incidência durante o verão e início do outono, quando se combinam altas temperaturas e aumento da precipitação, fatores conhecidos por favorecerem a proliferação do vetor *Aedes aegypti*. Tais padrões sazonais sustentam a importância de estratégias de antecipação, como modelos preditivos baseados em séries temporais, que considerem essas flutuações cíclicas.




Figura 2. Distribuição acumulada das notificações de dengue por semana epidemiológica no Brasil (2000–2025)

Fonte: Resultados originais da pesquisa

A estratificação dos dados por macrorregiões do país permite observar nuances importantes na dinâmica da dengue (Figura 3). Embora todas as regiões apresentem a mesma sazonalidade básica, a magnitude e a intensidade dos surtos variam substancialmente.




Figura 3. Evolução anual das notificações de dengue no Brasil por região geográfica

Fonte: Resultados originais da pesquisa

A região Sudeste, em particular, apresenta os maiores volumes absolutos de notificações ao longo de todo o período analisado. Essa predominância se acentua nos anos de maior incidência nacional, como 2010, 2013, 2015 e 2024. Já a região Norte, por exemplo, apresenta um padrão mais disperso e menos concentrado, enquanto o Sul tende a registrar surtos menores e menos regulares, comportamento possivelmente associado às temperaturas mais amenas e à menor densidade urbana em determinadas áreas.

A compreensão da magnitude real de uma epidemia exige mais do que o simples acompanhamento dos números absolutos de casos. No contexto de vigilância epidemiológica o indicador de notificações por 100 mil habitantes é muito difundido (Fundação Nacional de Saúde, 2002). Trata-se de uma taxa de incidência padronizada pelo tamanho da população, desta forma permitindo comparações onde o tamanho das populações nas amostras seja neutralizado. Desta forma é possível comparar efetivamente a intensidade de epidemias em municípios, estados ou países diferentes. Em outras palavras, elimina-se o viés de que um lugar com mais habitantes naturalmente teria mais casos absolutos.

A avaliação das notificações por 100 mil habitantes no Brasil entre 2001 e 2024 (Figura 4) demonstra que o ano de 2024 apresentou um salto notável em praticamente todas as regiões do país, com destaque para Sudeste, Centro-Oeste e Sul, cujos índices ultrapassam a marca de 4.000 casos por 100 mil habitantes. Esse valor representa uma incidência superior a 4% da população em apenas um ano, um dado alarmante que evidencia a gravidade da epidemia.




Figura 4. Evolução anual da taxa de notificações por 100 mil habitantes nas regiões do Brasil
Fonte: Resultados originais da pesquisa

Ao longo dos anos, o Centro-Oeste frequentemente liderou o ranking proporcional, com surtos intensos e repetidos. Essa região é historicamente reconhecida por combinar clima

quente e úmido, urbanização crescente e desafios estruturais, o que favorece o ciclo de reprodução do *Aedes aegypti*. O Sudeste, por sua vez, mantém uma presença constante entre as regiões com maior carga proporcional, ainda que com picos intercalados, demonstrando uma tendência de consolidação da dengue como problema recorrente e sistemático. O Nordeste e o Norte apresentam comportamentos mais variáveis, enquanto o Sul, tradicionalmente menos afetado, registrou em 2024 uma das maiores taxas de toda a série, sugerindo uma possível expansão territorial da doença para áreas antes consideradas de menor risco.

Em 2024, observa-se pela primeira vez uma convergência significativa entre as curvas das regiões mais e menos afetadas, o que pode indicar um colapso dos padrões regionais históricos. Esse comportamento pode estar associado a múltiplos fatores: mudanças climáticas, aumento da mobilidade populacional, dispersão de sorotipos e sobrecarga dos sistemas de vigilância e controle.

Diante desse cenário, a análise regional permite identificar que a dengue, embora endêmica em todo o território nacional, não se distribui de forma homogênea, seja em termos absolutos ou proporcionais. A intensidade com que diferentes regiões têm sido atingidas justifica a necessidade de estratégias específicas, territoriais e orientadas por evidências.

Entre as regiões analisadas, o Sudeste destaca-se por três motivos centrais: (i) o elevado número absoluto de notificações ao longo dos anos; (ii) a consolidação de picos epidêmicos bem definidos e regulares; e (iii) a alta incidência proporcional registrada em 2024. Esses elementos combinados apontam para a necessidade de aprofundamento do estudo nesta região, com foco na compreensão das variações internas e da dinâmica local dos surtos.

Após a delimitação da região Sudeste como foco principal da análise, tornou-se necessário realizar uma nova redução da escala territorial.

Seleção e caracterização dos municípios prioritários da região Sudeste

Ainda que o Sudeste seja apenas uma entre cinco macrorregiões brasileiras, ele abriga quase metade da população nacional e concentra cerca de 30% dos municípios do país (IBGE, 2025). Essa densidade administrativa e populacional, embora represente uma riqueza de informações, também impõe desafios computacionais significativos, especialmente quando se considera a possibilidade de integração de variáveis climáticas e demográficas a nível municipal. Além disso, a inclusão indiscriminada de municípios pouco expressivos do ponto de vista epidêmicos poderia introduzir ruído estatístico, afetando a robustez das análises preditivas.

Dessa forma, a seleção dos municípios prioritários do Sudeste foi guiada conforme os critérios citados na metodologia: (i) população média entre 2013 e 2024 igual ou superior a 500 mil habitantes (segundo dados anuais do IBGE); e (ii) incidência média de dengue superior a 500 casos por 100 mil habitantes no mesmo período.

Esses dois filtros garantem que os municípios selecionados representem tanto massas populacionais significativas, quanto atividade epidêmica real e recorrente, excluindo territórios que poderiam inflar o volume de dados sem contribuir com padrões válidos para modelagem.

A partir dessa metodologia, foram selecionados 13 municípios distribuídos entre os estados de São Paulo, Minas Gerais e Rio de Janeiro. Entre eles, destacam-se:

São Paulo (SP), com a maior população absoluta e o maior volume de notificações totais, além de um surto expressivo em 2024; Belo Horizonte (MG), Guarulhos (SP), Campinas (SP) e Contagem (MG), que apresentaram padrões epidêmicos cíclicos e bem definidos, com picos em anos específicos (ex: 2016, 2019 e 2024); Juiz de Fora (MG), Uberlândia (MG) e São Bernardo do Campo (SP), cujas curvas mostram oscilações menos previsíveis, mas ainda com volumes significativos; Sorocaba, Osasco, Niterói, Ribeirão Preto e São José dos Campos, que completam o conjunto com padrões mistos, representando uma boa diversidade de comportamentos epidêmicos.

A Figura 5 ilustra exemplos desses perfis heterogêneos comparando três cidades-chave (São Paulo, Belo Horizonte e Niterói). Ainda que todos atendam aos critérios técnicos de seleção, seus padrões de comportamento da dengue ao longo dos anos são bastante distintos.




Figura 5. Evolução anual normalizada das notificações de dengue nos municípios de São Paulo, Belo Horizonte e Niterói (2013–2025)

Fonte: Resultados originais da pesquisa

A cidade de Belo Horizonte exibe uma ciclicidade notável, com picos regulares e intensos ao longo da série, sugerindo a presença de fatores estruturais e/ou ambientais estáveis que favorecem a recorrência de surtos. Por outro lado, São Paulo, apesar de sua relevância populacional, manteve o número de notificações em patamares baixos até 2024, quando apresentou um surto abrupto, isolado e de alta intensidade. Esse comportamento levanta hipóteses sobre a presença de gatilhos contextuais recentes: mudanças no clima, circulação de novos sorotipos, colapso de medidas de controle vetorial ou aumento na subnotificação anterior.

Niterói, por sua vez, apresenta uma curva mais irregular e suavizada, com uma explosão em 2013 seguida por anos de baixa intensidade, incluindo 2024, quando outros municípios estavam em situação mais crítica. Esse contraste sugere que os fatores determinantes da transmissão da dengue variam entre os territórios, seja em função de características socioeconômicas, cobertura de saneamento, políticas locais de vigilância ou mesmo variáveis climáticas.

Com base nisso, a etapa seguinte deste trabalho dedica-se à aplicação de modelos preditivos univariados, utilizando séries temporais específicas para cada município. O objetivo é avaliar, em um primeiro momento, o poder de previsão com base apenas nos dados históricos de notificações, para então mensurar o valor agregado da introdução de variáveis externas em modelos futuros.

Modelagem Preditiva com Séries Temporais Univariadas

Considerando as variações dos padrões de incidência de dengue entre os municípios, optou-se por construir um conjunto de modelos preditivos com base nas séries históricas de cada município, de modo a avaliar a capacidade dos modelos univariados de capturar padrões reais de evolução da dengue e identificar suas limitações.

O foco desta etapa foi a criação de um conjunto de modelos “baseline”, ou seja, modelos estatísticos simples e clássicos que servem como referência inicial para comparação futura com abordagens mais robustas e multivariadas. Esses modelos foram avaliados individualmente em cada município, utilizando dados históricos da própria série como fonte única de informação.

O conjunto de modelos aplicados foi estruturado com o intuito de permitir uma comparação entre abordagens de complexidade crescente, indo desde projeções simples até técnicas estatísticas mais sofisticadas. Inicialmente, foram testados modelos considerados “baseline”, como o modelo “Naive”, que replica o último valor observado ao longo do tempo; o modelo de Média (“Mean”), que utiliza o valor médio da série como previsão estática; e o

modelo “Drift”, que projeta a tendência observada entre o primeiro e o último ponto da série de treino para estimar valores futuros (Hyndman e Athanasopoulos, 2018). Esses modelos, ainda que rudimentares, são fundamentais para servir de referência na avaliação de desempenho dos demais.

Em seguida, foram utilizados modelos baseados em suavização exponencial, capazes de captar tendências e padrões mais sutis nas séries. O modelo “Simple Exponential Smoothing” [SES] assume ausência de tendência ou sazonalidade, sendo útil para séries estacionárias. Já o modelo de Holt incorpora uma componente de tendência linear, enquanto o modelo Holt-Winters Aditivo acrescenta ainda uma componente de sazonalidade com amplitude constante. Esses modelos são particularmente interessantes para séries que apresentam variações cíclicas sem grandes desvios estruturais entre os ciclos (Hyndman e Athanasopoulos, 2018).

Por fim, aplicaram-se modelos estatísticos clássicos para séries temporais com estrutura dependente no tempo. O modelo “Auto Regressive Integrated Moving Average” [ARIMA] foi calibrado para diferentes combinações de parâmetros (p , d , q), permitindo captar componentes autorregressivos, de diferenciação e de média móvel. Complementarmente, o modelo “Seasonal Auto Regressive Integrated Moving Average” [SARIMA], uma extensão do ARIMA com componentes sazonais explícitos, foi estruturado para captar a forte sazonalidade observada (Hyndman e Athanasopoulos, 2018).

O ano de 2023 foi escolhido como janela de teste dos modelos por representar um cenário epidêmicos mais adequado ao escopo desta etapa, cujo objetivo é avaliar a capacidade de predição de modelos univariados baseados exclusivamente em padrões históricos da série.

Como forma de ilustrar os comportamentos resultantes das diferentes abordagens preditivas, selecionou-se o município de Ribeirão Preto como estudo de caso visual, por se tratar de uma localidade com padrão cíclico consistente e volume expressivo de notificações. Na subseção a seguir, são apresentados os gráficos comparativos das previsões geradas por cada grupo de modelos, com foco no ano de 2023, acompanhados de uma breve análise interpretativa sobre os acertos e limitações observados em cada abordagem.

Modelos Simples de Séries Temporais

A Figura 6 apresenta as previsões geradas pelos modelos “Naive”, “Mean” e “Drift”. Como esperado, esses modelos produzem estimativas constantes ou linearmente projetadas, baseando-se apenas em regras mínimas da série de treino.




Figura 6. Previsões geradas pelos Modelos Simples para Ribeirão Preto no ano de 2023
Fonte: Resultados originais da pesquisa

O modelo “Naive” replicou o último valor observado, gerando uma linha praticamente plana, sem capacidade de adaptação ao ciclo epidêmico ocorrido em 2023. O modelo de Média apresentou uma superestimação constante ao longo de todo o ano, desconsiderando o recuo epidêmico do segundo semestre. Já o modelo “Drift” captou uma leve tendência de crescimento, mas também falhou em antecipar o comportamento real da curva.

Em conjunto, esses resultados confirmam que, embora úteis como referência, modelos simples são insuficientes para capturar a dinâmica temporal da dengue em contextos cíclicos como o de Ribeirão Preto, comportamento igualmente observado nos demais municípios analisados.

Modelos Clássicos de Suavização Exponencial

Os modelos de suavização exponencial para o município de Ribeirão Preto estão apresentados na Figura 7.




Figura 7. Previsões geradas pelos Modelos de Suavização Exponencial para Ribeirão Preto no ano de 2023
Fonte: Resultados originais da pesquisa

O modelo “Simple Exponential Smoothing” [SES] manteve previsões em torno de uma média suavizada, sem sensibilidade à tendência ou sazonalidade. Já o modelo de Holt conseguiu incorporar uma tendência linear crescente, porém com superestimação significativa na segunda metade do ano. O modelo Holt-Winters aditivo, por sua vez, demonstrou melhor aderência ao comportamento cíclico da série, ainda que com atraso no pico e subestimação da magnitude real.

Esses resultados sugerem que modelos de suavização exponencial são mais adequados do que os modelos simples, especialmente quando a série apresenta componentes estruturais. Entretanto, sua performance ainda é limitada pela incapacidade de ajustar sazonalidade com amplitude variável, como ocorre frequentemente em epidemias.

Modelos ARIMA e SARIMA

Na Figura 8 são apresentados os resultados dos três melhores modelos ARIMA aplicados à série de Ribeirão Preto: ARIMA (2,0,2), ARIMA (3,0,1) e ARIMA (3,0,2).




Figura 8. Previsões geradas pelos 3 melhores Modelos ARIMA para Ribeirão Preto no ano de 2023

Fonte: Resultados originais da pesquisa

Observa-se que, mesmo dentro dessa classe mais sofisticada de algoritmos, as previsões tendem a suavizar os picos e prolongar as descidas, indicando uma dificuldade em responder com precisão à abrupta elevação de casos ocorrida entre março e maio de 2023. Apesar disso, os modelos apresentam maior estabilidade e coerência geral, com menor tendência a erros extremos.

Destaca-se que ambos os 3 modelos ARIMA apresentaram melhor aderência no início do ano e se mantiveram mais próximos da curva real ao longo do tempo do que os demais modelos utilizados até aqui. No entanto, nenhum dos modelos ARIMA foi capaz de captar plenamente a intensidade e a forma do pico epidêmico.

Já a estrutura dos modelos SARIMA incorpora não apenas componentes autorregressivos e de média móvel na série regular, mas também termos sazonais que consideram o ciclo epidêmico anual (com periodicidade de 52 semanas).

Embora o ajuste sazonal represente um avanço teórico em relação aos modelos ARIMA, os resultados práticos revelam limitações importantes, como pode-se observar na Figura 9.




Figura 9. Previsões geradas pelos 3 melhores Modelos SARIMA para Ribeirão Preto no ano de 2023

Fonte: Resultados originais da pesquisa

Em especial, observa-se que os modelos apresentaram valores previstos negativos em diversos momentos do segundo semestre. Ainda que matematicamente possível em modelos lineares, esse comportamento viola o limite lógico mínimo da série (zero casos notificados), e compromete a plausibilidade interpretativa da previsão, o que também foi observado em outros estudos, como elucidado por Sathish et al. (2020).

Apesar de violar em alguns casos o limite lógico da série, os modelos SARIMA foram capazes de capturar com certa precisão a intensidade da curva real, em especial o crescimento acelerado entre fevereiro e abril, seguido por um pico abrupto em maio. Em alguns municípios as previsões geradas apresentaram comportamento mais amortecido, com subestimação do pico e tendência à suavização excessiva ao longo do tempo. Isso sugere que, com a inclusão de componentes sazonais, os modelos SARIMA possuem boa capacidade de captar a complexidade da dinâmica epidêmica da dengue em certos contextos.

Algumas das limitações encontradas reforçam a necessidade de incorporar variáveis explicativas externas (como temperatura, precipitação, densidade populacional ou mobilidade urbana), que poderiam ajudar a antecipar eventos abruptos e comportamentos atípicos que não estão contidos na própria série histórica.

A aplicação dos modelos univariados permitiu obter uma primeira avaliação preditiva da série histórica de casos de dengue nos municípios priorizados da região Sudeste. Com o uso de diferentes abordagens, desde modelos simples, como “Naive” e “Drift”, até técnicas estatísticas clássicas, como Holt-Winters, ARIMA e SARIMA, buscou-se compreender em que medida os padrões epidêmicos locais poderiam ser reproduzidos e antecipados com base apenas nos próprios dados históricos de notificações.

A Tabela 1 apresenta o desempenho dos melhores modelos para cada município, considerando as três métricas de erro.

Tabela 1. Resultados dos Melhores Modelos Preditivos Univariados por Município no ano de 2023

Município	Modelo	Tipo	MAE	RMSE	MAPE
Belo Horizonte	SARIMA (2, 1, 2) (1, 1, 1, 52)	SARIMA	374,54	476,14	163,00%
Campinas	SARIMA (2, 1, 0) (1, 1, 0, 52)	SARIMA	111,69	147,02	85,13%
Contagem	ARIMA (1,0,0)	ARIMA	146,29	183,30	322,51%
Guarulhos	SARIMA (2, 1, 0) (1, 1, 0, 52)	SARIMA	9,68	13,67	35,65%
Juiz de Fora	SARIMA (1, 1, 2) (1, 1, 0, 52)	SARIMA	27,25	47,51	53,58%
Niterói	ARIMA (3,1,3)	ARIMA	2,93	5,25	25,48%
Osasco	SARIMA (0, 1, 1) (0, 1, 1, 52)	SARIMA	12,89	24,34	42,11%
Ribeirão Preto	SARIMA (1, 1, 2) (1, 1, 0, 52)	SARIMA	177,53	244,51	91,84%
Sorocaba	SARIMA (2, 1, 0) (1, 1, 0, 52)	SARIMA	109,82	153,34	292,23%
São Bernardo do Campo	SES	Suavização Exponencial	3,01	5,03	23,86%
São José dos Campos	ARIMA (2,1,0)	ARIMA	15,96	27,23	39,85%
São Paulo	SARIMA (2, 1, 0) (1, 1, 0, 52)	SARIMA	92,45	155,74	34,28%
Uberlândia	Holt-Winters	Suavização Exponencial	299,25	504,02	49,54%

Fonte: Resultados originais da pesquisa

Os resultados indicam que os modelos da família ARIMA e SARIMA apresentaram o melhor desempenho geral, sendo os mais recorrentes entre os modelos selecionados como “vencedores” nos municípios analisados. Isso se deve à sua capacidade de capturar a estrutura da série, ou seja, o comportamento geral da curva, incluindo os períodos de crescimento, estabilização e queda. Ainda assim, esses modelos não foram capazes de antecipar com precisão a intensidade dos surtos, tampouco de identificar o momento exato

de inflexão da curva epidêmica em alguns dos municípios avaliados. Em diversas situações, houve subestimação dos picos ou atraso na identificação do início da elevação nos casos.

Outro ponto a se destacar é a performance de modelos de suavização exponencial como SES ou Holt-Winters Aditivo em municípios com baixa ou nenhuma atividade epidêmica no ano de 2023. Nesses casos, o erro foi reduzido porque a série real apresentou baixos volumes e pouca oscilação, o que favorece previsões planas ou suavizadas. No entanto, isso não indica que esses modelos são, de fato, eficazes para antecipar surtos, mas apenas que foram suficientes para séries “calmas”. Isso reforça a necessidade de avaliar o desempenho dos modelos à luz do contexto epidêmico de cada local.

A análise geral evidencia que, ainda que os modelos univariados consigam captar padrões históricos, eles não são capazes de explicar ou prever mudanças abruptas na série, como os surtos epidêmicos atípicos. Isso ocorre porque os modelos aqui aplicados se baseiam exclusivamente na série de notificações, ignorando completamente fatores exógenos, como clima, circulação viral, comportamento populacional, mobilidade urbana, políticas públicas ou cobertura vacinal.

Dados Climáticos

Diante das limitações observadas na etapa anterior, em que modelos univariados, baseados exclusivamente na série histórica de notificações, apresentaram dificuldades em antecipar picos epidêmicos e variações abruptas em alguns municípios, tornou-se necessário incorporar fatores externos que pudessem atuar como preditores relevantes da dinâmica da dengue.

Nesse sentido, as variáveis climáticas destacam-se na literatura como elementos fundamentais para compreensão e previsão da transmissão da dengue, dada a forte dependência do vetor *Aedes aegypti* em relação a condições ambientais como temperatura, umidade e precipitação (Lai Y. H., 2018).

Com base nos 13 municípios prioritários da região Sudeste, previamente selecionados, observou-se a necessidade de identificação para cada município qual seria a melhor estação meteorológica, uma etapa essencial para garantir que as séries climáticas fossem representativas das condições ambientais locais.

Para operacionalizar essa associação, aplicou-se a métrica de Haversine, que calcula a menor distância esférica entre dois pontos na superfície terrestre com base em suas coordenadas geográficas (latitude e longitude). O algoritmo identificou, para cada município, a estação meteorológica, conforme demonstrado na Tabela 2.

Tabela 2. Estações Meteorológicas por Município

Município	Estação	Código da Estação
Uberlândia	Uberlândia	A507
São José Dos Campos	Monte Verde	A509
Belo Horizonte	Belo Horizonte - Pampulha	A521
Contagem	Belo Horizonte - Pampulha	A521
Juiz De Fora	Niterói	A627
Niterói	Niterói	A627
Ribeirão Preto	Pradópolis	A747
Campinas	Barueri	A755
Sorocaba	Barueri	A755
Osasco	Barueri	A755
São Paulo	São Paulo - Interlagos	A771
Guarulhos	São Paulo - Interlagos	A771
São Bernardo Do Campo	São Paulo - Interlagos	A771

Fonte: Resultados originais da pesquisa

Com as estações meteorológicas determinadas, foram realizadas solicitações ao INMET para extração de dados climáticos diários, por estação, no período de 2010 a 2025. O processo, conduzido por meio do portal oficial da instituição, resultou no envio dos arquivos por e-mail, contendo as seguintes variáveis climáticas: Precipitação total (mm), Pressão atmosférica média (hPa), Temperatura média (°C), Temperatura máxima (°C), Temperatura mínima (°C), Umidade relativa média (%), Umidade relativa mínima (%) e Velocidade média das rajadas de vento (m/s).

Esses dados foram limpos, padronizados e agregados em frequência semanal, de forma a manter compatibilidade com a série de notificações de dengue por semana epidemiológica. Para cada município, construiu-se assim uma base integrada contendo tanto o número de casos quanto as variáveis climáticas semanais estimadas a partir da estação meteorológica mais próxima.

Análise de Defasagens (“Lags”)

Além da disponibilidade de dados climáticos integrados aos municípios prioritários, é crucial compreender como e quando essas variáveis exercem influência sobre os surtos de dengue. Essa relação não é imediata: há um intervalo natural entre a ocorrência de eventos climáticos, como chuvas intensas, e o impacto observável na série de notificações da doença, conforme elucidado por Hii Y. L. et al. (2012).

Esse intervalo de tempo é denominado “lag”, ou defasagem temporal, e está diretamente relacionado ao ciclo de vida do vetor *Aedes aegypti*. Após períodos de chuva, criadouros são formados, permitindo a eclosão de ovos e o desenvolvimento das larvas. O processo, que inclui a fase adulta do mosquito, a infecção viral e o surgimento de sintomas na população, demanda algumas semanas até se refletir em notificações oficiais nos sistemas de vigilância epidemiológica.

A Figura 10 ilustra essa defasagem no município de Ribeirão Preto, evidenciando o comportamento da variável precipitação total ao longo do tempo em relação às notificações semanais de dengue. Observa-se claramente que os picos de precipitação (linha azul) antecedem, por algumas semanas, os picos epidêmicos (linha preta), sugerindo uma relação causal defasada entre as duas séries.




Figura 10. Precipitação total (mm) e notificações semanais de dengue em Ribeirão Preto
Fonte: Resultados originais da pesquisa

O reconhecimento desse atraso é essencial para a modelagem preditiva, pois, ao incorporar variáveis climáticas defasadas, por exemplo, a precipitação com 6 ou 8 semanas de antecedência, os modelos ganham capacidade de antecipar variações futuras nas notificações, e não apenas explicar variações simultâneas. Isso torna a modelagem mais robusta e aplicável à lógica de prevenção antecipada, aumentando a utilidade dos modelos no suporte à tomada de decisão em saúde pública.

A análise de “lag” foi realizada para todas as variáveis climáticas e todos os municípios da amostra.

Modelagem Preditiva com Séries Temporais Multivariadas

Após a incorporação das variáveis climáticas e a identificação de suas defasagens temporais mais relevantes por município, avançou-se para a construção de modelos preditivos multivariados, com o objetivo de melhorar a capacidade de antecipação dos surtos de dengue. Ao contrário dos modelos univariados, que se baseiam unicamente na série histórica de notificações, os modelos multivariados incorporam fatores exógenos que afetam direta ou indiretamente a dinâmica da transmissão, como temperatura, umidade e precipitação.

Essa abordagem busca capturar relações mais complexas e realistas, refletindo a multifatorialidade envolvida na ocorrência de epidemias. As variáveis climáticas foram utilizadas em suas versões defasadas (conforme identificado na etapa anterior), compondo um conjunto explicativo para prever o número de casos notificados semanalmente em cada município.

A construção dos modelos multivariados contemplou três famílias de modelagem, escolhidas para cobrir diferentes estruturas de relação entre variáveis: (i) modelos lineares generalizados [GLMs] de contagem, adequados para variáveis inteiras e não negativas; (ii) algoritmos baseados em árvores de decisão e ensembles, capazes de capturar não linearidades e interações sem necessidade de transformações explícitas; e (iii) redes neurais do tipo LSTM, indicadas para dependências temporais de médio e longo prazo.

Modelos GLM de Contagem

Os modelos de “Generalized Linear Models” [GLM] de contagem foram aplicados devido a capacidade de lidar com variáveis (não negativas) e inteiras. Foram avaliados modelos de regressão de Poisson (que assumem equidispersão, isto é, variância igual à média) e Binomial Negativa (que introduz um parâmetro de dispersão extra, acomodando variâncias maiores que a média) para cada série municipal (Lai Y. H., 2018).

Conforme esperado, praticamente todas as séries municipais apresentaram sobredispersão acentuada, a variância dos casos superando em muito a média, o que viola a premissa do modelo de Poisson.

A Figura 11 apresenta as previsões geradas pelos modelos GLM (tanto Poisson quanto Binomial Negativa) para o município de Ribeirão Preto no ano de 2023.




Figura 11. Previsões geradas pelos Modelos de GLMs de Contagem para Ribeirão Preto no ano de 2023

Fonte: Resultados originais da pesquisa

As previsões mantiveram-se sempre em valores não negativos, um aspecto garantido pela natureza desses modelos de contagem, evitando anomalias como valores negativos estimados (problema observado anteriormente em alguns modelos univariados). Contudo, mesmo com variáveis exógenas climáticas, os modelos anteciparam o pico epidêmico e superestimaram sua magnitude no primeiro semestre. Em geral, projetaram máximos em fevereiro–março com valores próximos ou acima de 1,6–1,7 mil notificações/semana, enquanto a curva real atingiu o ápice apenas em maio, em patamar mais baixo.

Após esse desvio antecipado, as previsões iniciaram a queda antes do observado, gerando um deslocamento temporal do ciclo. A série do segundo semestre apresentou aderência razoável, mas o “timing” e o tamanho do surto no início do ano permaneceram mal representados.

Sem mecanismos explícitos de memória longa ou componentes autorregressivos/sazonais internos à própria dinâmica da série, os GLM mostraram-se capazes de explicar a tendência média, mas não o acoplamento fino entre clima e surtos que auxilia a determinar os momentos de maior intensidade das notificações.

Em suma, apesar de introduzirem melhorias importantes (como o respeito aos limites lógicos da série e a consideração explícita da variância não constante dos dados), os modelos GLM univariados demonstraram limitações significativas na previsão de mudanças abruptas na dinâmica da dengue.

Esses achados reforçam que, embora os GLM forneçam maior capacidade preditiva do que os modelos, especialmente em contextos de dados de contagem, abordagens mais

robustas ou informações adicionais serão necessárias para melhorar a acurácia preditiva em cenários epidêmicos altamente dinâmicos.

Modelos de Árvores de Decisão e Ensemble

Quanto aos modelos de árvores de decisão e ensemble, três abordagens foram escolhidas: Decision Tree, Random Forest (média de muitas árvores, com amostragem de dados e variáveis) e XGBoost (adição sequencial de árvores corrigindo os erros residuais). Todas usaram as mesmas variáveis climáticas e “lags” definidos anteriormente, no mesmo recorte temporal.

A Figura 12 mostra a previsão por Decision Tree e Random Forest. Ambos os modelos capturaram corretamente que a maior atividade se concentrou no primeiro semestre e que o segundo semestre teve níveis baixos e estáveis. Entretanto, produziram picos muito irregulares e superestimados entre fevereiro e abril e anteciparam o pico em relação à curva real, semelhante ao ocorrido com os modelos GLM. Ao combinar muitas árvores, o modelo Random Forest reduziu os picos espúrios do primeiro semestre e desenhou melhor a subida e a queda do surto, ainda que com lacunas importantes (alguns picos seguem adiantados e/ou superestimados). No segundo semestre, a série prevista se manteve praticamente constante em ambas as previsões, com pouca sensibilidade às flutuações de baixa intensidade. Esse comportamento é típico de árvores de decisão: alta variância no período crítico e pouca suavização fora dele.




Figura 12. Previsões geradas pelos modelos Decision Tree e Random Forest para Ribeirão Preto no ano de 2023

Na Figura 13, o XGBoost apresentou a melhor aderência global. O modelo acertou com mais precisão o momento de inflexão (início de subida e pico do primeiro semestre) e controlou melhor a altura dos picos, apesar de manter nível acima do esperado em parte do segundo semestre e de adiantar levemente o ápice. Ainda assim, a forma geral da curva e o “timing” ficaram mais próximos da série real do que nos demais modelos em árvore.




Figura 13. Previsões geradas pelo modelo XGBoost para Ribeirão Preto no ano de 2023
Fonte: Resultados originais da pesquisa

Os resultados confirmaram o racional de testar os modelos de árvores e, sobretudo, ensembles. A capacidade de aprenderem limiares e combinações entre variáveis climáticas e seus “lags”, representam aspectos que os modelos lineares não capturaram. Em Ribeirão Preto, XGBoost foi o que mais se aproximou da dinâmica observada, seguido pelo Random Forest e, por último, Decision Tree. Persistiram, porém, dois desafios comuns: superestimação no auge e tendência elevada no segundo semestre. Esses pontos sustentam os próximos passos com modelos que incorporem memória temporal de forma explícita.

Modelos de Redes Neurais LSTM

A rede neural LSTM é uma arquitetura recorrente desenvolvida para captar dependências de longo prazo em séries temporais, sendo especialmente útil para dados com padrão temporal complexo. Sua estrutura interna utiliza “portas” que regulam o fluxo de informação, sendo eficaz para prever séries com ruído, sazonalidade e efeitos acumulativos (Skansi, 2018).

Por outro lado, justamente por ter alta capacidade de processar as informações, redes neurais tendem a superajustar os dados (“overfitting”), fenômeno onde decora-se os dados de treino, inclusive ruídos da série, ao invés de se compreender o comportamento do alvo.

Segundo Ying X., (2019) para mitigar esse risco, deve-se adotar um conjunto de salvaguardas complementares: validação em ordem temporal (treino/validação/teste separados no tempo), regularização explícita (“dropout”), parada antecipada do treinamento quando a validação deixou de melhorar (“early stopping”) e monitoramento de perdas e erros em treino versus validação, assegurando equilíbrio entre ajuste e generalização.

Dada a capacidade do LSTM de reter dependências de curto e longo prazo em sequências (via mecanismos de “memória”), dividiu-se sua aplicação em três frentes: (i) univariada (apenas histórico de notificações), (ii) multivariada (histórico + variáveis climáticas) e (iii) apenas climática (somente variáveis climáticas com suas defasagens). Essa separação foi planejada para responder a provocações metodológicas relativas ao desempenho observado dos modelos multivariados decorrer apenas da arquitetura (memória do LSTM aplicada à série), da informação exógena (clima) ou da combinação de ambos.

No conjunto de 13 municípios priorizados, a configuração Histórico+Clima apresentou o melhor desempenho em 8 casos (Belo Horizonte, Contagem, Guarulhos, Juiz de Fora, Niterói, Osasco, São José dos Campos e Uberlândia). Em 4 municípios, somente o clima já foi suficiente para superar as demais variantes (Campinas, Sorocaba, São Bernardo do Campo e São Paulo). Ribeirão Preto foi o único caso em que a melhor configuração foi apenas o histórico, o que reforça a heterogeneidade espacial da relação entre clima e notificações. A Figura 14 ilustra as três previsões para Ribeirão Preto, evidenciando o comportamento específico desse município frente às diferentes fontes de informação.




Figura 14. Previsões geradas pelos modelos LSTM para Ribeirão Preto no ano de 2023
Fonte: Resultados originais da pesquisa

A Tabela 3 apresenta, para cada município, o melhor modelo entre GLM, árvores/ensembles, LSTM e os univariados utilizados como “baseline”, bem como os respectivos MAE, RMSE e MAPE. Essa consolidação permitiu: (i) quantificar o ganho efetivo

trazido pela informação climática defasada; (ii) selecionar o modelo a ser priorizado operacionalmente em cada município.

Tabela 3. Resultados dos Melhores Modelos Preditivos por Município no ano de 2023

Município	Modelo	Tipo	MAE	RMSE	MAPE
Belo Horizonte	SARIMA (2, 1, 2) (1, 1, 1, 52)	SARIMA	374,54	476,14	163,00%
Campinas	SARIMA (2, 1, 0) (1, 1, 0, 52)	SARIMA	111,69	147,02	85,13%
Contagem	Poisson	GLM	100,58	151,44	239,52%
Guarulhos	SARIMA (2, 1, 0) (1, 1, 0, 52)	SARIMA	9,68	13,67	35,65%
Juiz de Fora	Poisson	GLM	24,9	41,8	123,71%
Niterói	LSTM (Histórico+Clima)	Redes Neurais	2,7	4,36	71,06%
Osasco	SARIMA (0, 1, 1) (0, 1, 1, 52)	SARIMA	12,89	24,34	42,11%
Ribeirão Preto	LSTM (Histórico)	Redes Neurais	85,61	112,32	76,96%
Sorocaba	LSTM (Clima)	Redes Neurais	105,52	144,5	887,4%
São Bernardo do Campo	SES	Suavização Exponencial	3,01	5,03	23,86%
São José dos Campos	LSTM (Histórico+Clima)	Redes Neurais	18,89	21,76	209,84%
São Paulo	Binomial Negativa	GLM	96,81	136,86	45,58%
Uberlândia	Holt-Winters	Suavização Exponencial	299,25	504,02	49,54%

Fonte: Resultados originais da pesquisa

Confirmou-se que a incorporação de variáveis climáticas defasadas elevou a capacidade de antever a dinâmica epidêmica em cerca de metade dos municípios. Após a integração das séries do INMET, observou-se melhora do desenho da curva no primeiro semestre, exatamente onde os univariados haviam falhado com mais frequência. Contudo, apenas a sazonalidade e o histórico de notificações de dengue, já proporciona bons resultados de previsão. Nem todos os municípios possuem correlação forte entre clima e dengue, o que gera as diferentes possibilidades de modelagem.

Em síntese, os resultados foram município-dependentes. Verificou-se variação do algoritmo com melhor resultado em localidades onde o clima explicou boa parte da variabilidade: GLM de contagem (Contagem, Juiz de Fora, São Paulo), LSTM com histórico+clima (Niterói, São José dos Campos) e LSTM apenas com clima (Sorocaba). Nos univariados, destacaram-se SARIMA/SES/Holt-Winters (Belo Horizonte, Campinas, Guarulhos, Osasco, São Bernardo do Campo, Uberlândia) e um caso de LSTM univariada em Ribeirão Preto.

Conclusão

Este trabalho demonstrou que é possível construir, com dados públicos, um modelo preditivo de dengue capaz de antecipar a dinâmica epidêmica em escala municipal, agregada semanalmente e calibrada por território. A estratégia em duas frentes: (i) modelagem univariada para estabelecer um “baseline” robusto e (ii) modelagem multivariada com variáveis climáticas; permitiu demonstrar de forma objetiva o ganho informacional trazido pelo clima e da própria série histórica de notificações.

A vantagem multivariada surge onde as variáveis climáticas defasadas adicionam sinal antecipatório à onda epidêmica, enquanto a manutenção de univariados é coerente com localidades em que sazonalidade e autocorrelação do próprio histórico já descrevem bem a dinâmica. Entre as famílias, GLM de contagem (Poisson/Binomial Negativa) preservaram coerência com a natureza discreta e acomodaram sobredispersão, mas tenderam a antecipar/superestimar picos; Árvores/ensembles reduziram picos espúrios e melhoraram pontos de inflexão, sem se tornarem vencedores por município; já as LSTM apresentaram a melhor aderência temporal/morfológica quando multivariadas.

Em contrapartida, em cenários menos sensíveis às variáveis climáticas modelos univariados como SARIMA performaram melhor do que os multivariados. Estes municípios possuem característica marcante de sazonalidade anual estável, e uma autocorrelação forte. Em suma, este modelo prevalece quando há sazonalidade marcante e recorrente entre os anos, tornando-o competitivo e, por vezes, superior a modelos mais complexos.

Operacionalmente, os resultados sugerem um caminho claro para transformar vigilância reativa em gestão proativa de risco: um sistema de “early warning” municipalizado, atualizado semanalmente. Tal sistema pode subsidiar ações antecipatórias de controle vetorial, preparo assistencial e comunicação de risco com horizonte até 52 semanas, janela compatível com os “lags” bioclimáticos identificados, a depender de cada município.

Como toda análise aplicada a dados de saúde pública, há limitações. A subnotificação e atrasos no Sistema de Informação de Agravos de Notificação [SINAN], a representatividade

das estações do INMET (especialmente em áreas conurbadas) e a ausência de variáveis não climáticas críticas (vigilância vetorial, mobilidade, circulação viral, saneamento, cobertura vacinal) impõem teto ao poder preditivo.

Recomenda-se, para trabalhos futuros e evolução operacional: (1) inclusão de variáveis não climáticas (índices entomológicos, mobilidade, saneamento, variáveis sociodemográficas e circulação sorotípica), (2) adoção de modelos espaço-temporais e hierárquicos (SARIMAX, TES, GLMMs de contagem e redes espaço-temporais).

Em síntese, este trabalho oferece um roteiro pragmático para que secretarias municipais e estaduais avancem de previsões genéricas para estratégias preditivas territorializadas, mais precisas e, principalmente, úteis para salvar vidas.

Referências

Abdullah, N.A.M.H.; Dom, N.C.; Salleh, S.A.; Salim, H.; Precha, N. 2022. The association between dengue case and climate: a systematic review and meta-analysis. *One Health* 15: 100452.

Brasil. Fundação Nacional de Saúde [FUNASA]. 2002. Guia de Vigilância Epidemiológica. 5ed. FUNASA, Brasília, DF, Brasil. 842p. ISBN 85-7346-032-6.

Fávero, L.P. 2017. Manual de Análise de Dados: Estatística e Modelagem Multivariada com Excel, SPSS e Stata. Elsevier.

Gurgel-Gonçalves, R.; Oliveira, W.K.; Croda, J. 2024. The greatest dengue epidemic in Brazil: surveillance, prevention, and control. *Revista da Sociedade Brasileira de Medicina Tropical* 57: e00203-2024.

Gutiérrez-Bugallo, G.; Boullis, A.; Martinez, Y.; Hery, L.; Rodríguez, M.; Bisset, J.A.; Vega-Rúa, A. 2020. Vector competence of *Aedes aegypti* from Havana, Cuba, for dengue virus type 1, chikungunya, and Zika viruses. *PLoS Neglected Tropical Diseases* 14(12): e0008941.

Hii, Y.L.; Zhu, H.; Ng, N.; Ng, L.C.; Rocklöv, J. 2012. Forecast of dengue incidence using temperature and rainfall. *PLoS Neglected Tropical Diseases* 6(11): e1908.

Hyndman, R.J.; Athanasopoulos, G. 2018. Forecasting: Principles and Practice. OTexts.

Instituto Brasileiro de Geografia e Estatística [IBGE]. 2025. Panorama das Cidades do Brasil. Disponível em: <https://cidades.ibge.gov.br/brasil/panorama>. Acesso em: 15 jun. 2025.

Instituto Nacional de Meteorologia [INMET]. 2025. Banco de Dados Meteorológicos do INMET. Disponível em: <https://bdmep.inmet.gov.br/#>. Acesso em: 15 jun. 2025.

Khoirunnisa, A.; Ramadhan, N.G. 2023. Improving malaria prediction with ensemble learning and robust scaler: an integrated approach for enhanced accuracy. *Jurnal Infotel* 15(4): 326–334.

Lai, Y.H. 2018. The climatic factors affecting dengue fever outbreaks in southern Taiwan: an application of symbolic data analysis. *Biomedical Engineering Online* 17(Suppl 2): 148.

Lessa, C.L.S.; Hodel, K.V.S.; Gonçalves, M.D.S.; Machado, B.A.S. 2023. Dengue as a disease threatening global health: a narrative review focusing on Latin America and Brazil. *Tropical Medicine and Infectious Disease* 8(5): 241.

Lopez-Gatell, H.; Hernández-Ávila, M.; Hernández-Ávila, J.E.; Alpuche-Aranda, C.M. 2015. Dengue in Latin America: a persistent and growing public health challenge. In: *Neglected Tropical Diseases—Latin America and the Caribbean*: 203–224. Springer-Verlag, Vienna, Áustria.

Martelli, C.M.T.; Siqueira Jr., J.B.; Parente, M.P.P.D.; Zara, A.L.D.S.A.; Oliveira, C.S.; Braga, C.; Pimenta Jr., F.G.; Cortes, F.; Lopez, J.G.; Bahia, L.R.; Mendes, M.C.O.; da Rosa, M.Q.M.; de Siqueira Filha, N.T.; Constenla, D.; de Souza, W.V. 2015. Economic impact of dengue: multicenter study across four Brazilian regions. *PLoS Neglected Tropical Diseases* 9(9): e0004042.

Messina, J.P.; Brady, O.J.; Scott, T.W.; Zou, C.; Pigott, D.M.; Duda, K.A.; Bhatt, S.; Katzelnick, L.C.; Howes, R.E.; Battle, K.E.; Simmons, C.P.; Hay, S.I. 2014. Global spread of dengue virus types: mapping the 70-year history. *Trends in Microbiology* 22(3): 138–146.

Sathish, V.; Mukhopadhyay, S.; Tiwari, R. 2020. ARMA Models for Zero Inflated Count Time Series. *arXiv preprint arXiv:2004.10732*.

Sistema de Informação de Agravos de Notificação [SINAN]. 2025. Base dos Dados: Notificações de dengue – Brasil. Disponível em: <https://basedosdados.org/dataset/br-ms-sinan>. Acesso em: 15 jun. 2025.

Skansi, S. 2018. *Introduction to Deep Learning: From Logical Calculus to Artificial Intelligence*. Springer.

Teixeira, M.G.; Siqueira, J.B.; Ferreira, G.L.C.; Bricks, L.; Joint, G. 2013. Epidemiological trends of dengue disease in Brazil (2000–2010): a systematic literature review. *PLoS Neglected Tropical Diseases* 7(12): e2520.

Torres-Flores, J.M.; Ríos-Bagilet, L.A.; Méndez-Guerrero, O.; Salazar, M.I. 2022. Dengue vaccines: an update. *BioDrugs* 36(3): 325–336.

VanderPlas, J. 2023. *Python Data Science Handbook: Essential Tools for Working with Data*. O'Reilly Media.

Ying, X. 2019. An overview of overfitting and its solutions. *Journal of physics: Conference series* 1168: 022022.

Zeng, Z.; Zhan, J.; Chen, L.; Chen, H.; Cheng, S. 2021. Global, regional, and national dengue burden from 1990 to 2017: a systematic analysis based on the Global Burden of Disease Study 2017. *EClinicalMedicine* 32: 100712.